

Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

Objetivo

Ajustar Latent Dirichlet Allocation (LDA; Blei, Ng y Jordan, 2003) al corpus mínimo del curso —doce oraciones con tres temas reales (deporte, cocina, astronomía) que LDA no ve— para: (1) describir los temas latentes aprendidos con tres componentes (tamaño del vocabulario, cinco palabras más probables por tema y perplejidad); (2) comparar la perplejidad con 2, 3 y 4 temas; (3) medir mediante la pureza si LDA recupera los temas reales; y (4) discutir qué añade LDA frente a pLSI y por qué este corpus es un mal escenario para el modelo.

Método

Datos y vectorización. Corpus de 12 documentos (d01–d12), 4 por tema real. `CountVectorizer` con la lista de palabras vacías del enunciado (resto de parámetros por defecto): vocabulario de 71 términos y 91 tokens en total.

Modelo. `LatentDirichletAllocation(n_components=3, learning_method="batch", max_iter=50, random_state=0)`. En la Parte 2 se reajusta con el mismo vectorizador y parámetros usando 2, 3 y 4 temas, evaluando la perplejidad sobre el corpus completo (12 documentos), como pide el enunciado. En la Parte 3, el tema dominante de cada documento es el `argmax` de su distribución documento–tema, y la pureza se calcula sumando, para cada tema de LDA, los documentos de la etiqueta real más frecuente entre sus asignados, dividido por 12.

Código (resumen).

```
vec = CountVectorizer(stop_words=stop_words_del_enunciado)
X = vec.fit_transform(textos) # 12 docs, 71 terminos
lda = LatentDirichletAllocation(n_components=3, learning_method="batch",
                               max_iter=50, random_state=0).fit(X)
perplejidad = lda.perplexity(X) # Parte 1
# Parte 2: reajustar con n_components in (2, 3, 4) y registrar perplexity
# Parte 3: tema_dominante = lda.transform(X).argmax(axis=1); pureza
```

Resultados

Parte 1 — LDA con tres temas

Vocabulario de 71 términos (12 documentos, 91 tokens). Perplejidad del modelo sobre el corpus: **137.7877**.

Tema	Cinco palabras más probables
tema 1	planetas, órbita, partido, receta, azúcar
tema 2	equipo, partido, liga, ganó, goles
tema 3	sal, estrellas, nebulosa, galaxia, ajo

Solo el tema 2 agrupa palabras de una única categoría real; los temas 1 y 3 mezclan vocabulario de categorías distintas.

Parte 2 — Perplejidad con 2, 3 y 4 temas

Temas	Perplejidad	Log-verosimilitud total
2	107.8909	-425.9820
3	137.7877	-448.2400
4	156.4198	-459.7815

La perplejidad con 3 temas coincide exactamente con la de la Parte 1 (diferencia 0.0), con el mismo vocabulario de 71 términos.

Parte 3 — Pureza: ¿recupera LDA los temas reales?

Tema dominante por documento (la numeración 0–2 corresponde a los temas 1–3 de la Parte 1):

id	Etiqueta real	Tema LDA	Prob. del tema dominante	¿Bien agrupado?
d01	deporte	1	0.9320	sí
d02	deporte	0	0.9005	sí
d03	deporte	0	0.8985	sí
d04	deporte	1	0.9157	sí
d05	cocina	0	0.9294	no
d06	cocina	0	0.9135	no
d07	cocina	2	0.9236	sí
d08	cocina	2	0.9378	sí
d09	astronomía	2	0.9155	no
d10	astronomía	0	0.9160	no
d11	astronomía	2	0.9162	no
d12	astronomía	0	0.9149	no

Cuentas mayoritarias por tema LDA: tema 0 → deporte (2 de 6), tema 1 → deporte (2 de 2), tema 2 → cocina (2 de 4). **Pureza = $6/12 = 0.5$** . Quedan mal agrupados d05 y d06 (cocina, asignados al tema 0, de mayoría «deporte»), d10 y d12 (astronomía, asignados al tema 0) y d09 y d11 (astronomía, asignados al tema 2, de mayoría «cocina»).

Discusión

Qué añade LDA frente a pLSI. En pLSI el documento d es un índice ficticio de la lista de documentos de entrenamiento: el modelo aprende $p(z|d)$ solo para esos documentos, de modo que no es un modelo generativo bien definido y no hay forma natural de asignar probabilidad a un documento nuevo (la heurística de «folding-in» de Hofmann refittea $k-1$ parámetros sobre los datos de prueba). Además, sus parámetros ($kV + kM$) crecen linealmente con el número de documentos M , lo que lo hace propenso al sobreajuste. LDA añade un prior de Dirichlet sobre las proporciones de tema dentro del proceso generativo ($N \sim \text{Poisson}(\xi)$, $\theta \sim \text{Dir}(\alpha)$, $z_n \sim \text{Multinomial}(\theta)$, $w_n \sim p(w_n|z_n, \beta)$): cada documento es una mezcla aleatoria de temas, los parámetros no crecen con M y un documento nuevo recibe probabilidad de forma natural, sin heurísticas.

Por qué doce oraciones son un mal escenario para LDA. El corpus tiene solo 91 tokens repartidos en 12 documentos y un vocabulario de 71 términos: las estadísticas de co-ocurrencia son demasiado escasas para identificar bien las distribuciones documento–tema y tema–palabra. La consecuencia es visible en los temas: el tema 1 mezcla «planetas, órbita» con «partido, receta, azúcar» y el tema 3 mezcla «sal, ajo» con «estrellas, nebulosa, galaxia»; por eso la pureza cae a 0.5 y seis de los doce documentos quedan mal agrupados, aun cuando sus probabilidades dominantes son altas (la mínima es 0.8985, en d03). La perplejidad tampoco es un criterio de selección fiable aquí: disminuye al reducir el número de temas (107.8909 con 2 frente a 137.7877 con 3), pese a que el corpus tiene tres temas reales. En síntesis, LDA está concebido para colecciones grandes; con doce oraciones la posterior queda débilmente identificada y el resultado depende del prior y de la inferencia variacional más que de los datos.