

Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

Objetivo

Modelar un corpus mínimo de doce oraciones rotuladas en tres temas reales (deporte, cocina, astronomía) con Latent Dirichlet Allocation (LDA; Blei, Ng y Jordan, 2003). Se busca: (1) ajustar LDA con tres temas y reportar el vocabulario, las palabras más probables por tema y la perplejidad; (2) comparar la perplejidad con 2, 3 y 4 temas; (3) evaluar si los temas latentes recuperan las etiquetas reales mediante la pureza; y (4) discutir qué añade LDA frente a pLSI y por qué un corpus tan pequeño es un mal escenario para LDA.

Método

El corpus son doce oraciones (d01–d12), cuatro por etiqueta real. Cada texto se vectorizó con `CountVectorizer` usando la lista de palabras vacías del enunciado (el, la, los, las, de, del, en, y, a, un, una, por, para, con, se, su, al, es, después, durante, contra, donde, alrededor) y el resto de parámetros por defecto. Sobre la matriz de conteos se ajustó `LatentDirichletAllocation(n_components=3, learning_method="batch", max_iter=50, random_state=0)`.

- **Parte 1:** tamaño del vocabulario, cinco palabras más probables por tema y perplejidad sobre el corpus.
- **Parte 2:** con el mismo vectorizador y parámetros, LDA con $k = 2, 3$ y 4 temas y su perplejidad en una tabla.
- **Parte 3:** con el modelo de tres temas, tema dominante de cada documento (argmax de su distribución documento–tema) y pureza: para cada tema LDA se cuenta los documentos de la etiqueta real más frecuente entre los asignados a él; la suma se divide entre 12.
- **Parte 4:** discusión conceptual con base en Blei et al. (2003).

Resultados

Parte 1 — LDA con tres temas

El vocabulario tiene 71 palabras. La perplejidad del modelo con $k = 3$ sobre el corpus es 137.7877.

Tema (índice)	Cinco palabras más probables, $p(\text{palabra} \text{tema})$
0 (tema_1)	órbita (0.0351), planetas (0.0351), partido (0.0345), minutos (0.0200), huevos (0.0200)
1 (tema_2)	equipo (0.0600), partido (0.0596), liga (0.0341), ganó (0.0339), dos (0.0335)
2 (tema_3)	sal (0.0419), nebulosa (0.0419), galaxia (0.0419), estrellas (0.0419), ajo (0.0240)

Parte 2 — Número de temas (2, 3, 4)

La subtarea de la Parte 2 falló tras 3 intentos de ejecución, por lo que no se dispone de las perplejidades para $k = 2$ y $k = 4$. La única cifra disponible es la de $k = 3$, obtenida en la Parte 1.

k	Perplejidad
2	no disponible (subtarea fallida)
3	137.7877
4	no disponible (subtarea fallida)

Parte 3 — ¿Recupera LDA los temas reales?

Asignación por documento (índice del tema LDA: tema_1→0, tema_2→1, tema_3→2):

Documento	Etiqueta real	Tema dominante	$p(\text{tema})$	Bien agrupado
d01	deporte	1	0.9320	sí
d02	deporte	0	0.9005	sí

d03	deporte	0	0.8985	sí
d04	deporte	1	0.9157	sí
d05	cocina	0	0.9294	no
d06	cocina	0	0.9135	no
d07	cocina	2	0.9236	sí
d08	cocina	2	0.9378	sí
d09	astronomía	2	0.9155	no
d10	astronomía	0	0.9160	no
d11	astronomía	2	0.9162	no
d12	astronomía	0	0.9149	no

Cruce tema LDA vs. etiqueta real: tema 0 = {deporte: 2, cocina: 2, astronomía: 2}; tema 1 = {deporte: 2}; tema 2 = {cocina: 2, astronomía: 2}. La **pureza es $6/12 = 0.5$** , con seis documentos mal agrupados: d05 y d06 (cocina, asignados al tema 0, de mayoría «deporte») y d09, d10, d11 y d12 (astronomía, repartidos entre los temas 0 y 2, de mayorías «deporte» y «cocina»).

Discusión

Recuperación de los temas. Solo el tema 1 es puro (deporte). El tema 0 mezcla vocabulario de las tres etiquetas (órbita y planetas de astronomía, partido y minutos de deporte/cocina, huevos de cocina) y por eso absorbe documentos de las tres clases; el tema 2 mezcla cocina (sal, ajo) con astronomía (nebulosa, galaxia, estrellas). LDA se muestra muy seguro ($p(\text{tema dominante}) \geq 0.8985$ en los doce documentos), pero esa confianza no coincide con las etiquetas reales. Con doce oraciones muy cortas, las coocurrencias palabra–palabra son demasiado escasas para identificar la estructura temática y la inferencia converge a un óptimo local con temas mezclados. Un corpus de doce oraciones es así un mal escenario para LDA: hay pocos documentos y cortos, el prior de Dirichlet pesa más que la evidencia, la pureza y la perplejidad medidas sobre el mismo corpus son estimadores inestables, y aumentar k tendería a agravar el sobreajuste.

Qué añade LDA frente a pLSI. Según Blei et al. (2003), pLSI fija para cada documento de entrenamiento un conjunto de proporciones de tema $p(z|d)$, de modo que no es un modelo plenamente generativo: para valorar un documento nuevo debe recurrir a la heurística de «folding-in» sugerida por Hofmann y citada por Blei et al., que reajusta $k-1$ parámetros sobre los datos de prueba. Su sobreajuste «se deriva de la restricción de que cada documento futuro exhiba las mismas proporciones de temas observadas en uno o más documentos de entrenamiento». LDA añade un prior de Dirichlet sobre las proporciones de tema: cada documento se genera muestreando $\theta \sim \text{Dir}(\alpha)$ y, al marginalizar sobre θ , «LDA puede asignar fácilmente probabilidad a un documento nuevo; no se necesitan heurísticas», y el prior regulariza el modelo, controlando el sobreajuste que sufre pLSI al crecer k .

Limitación del entregable. La comparación de perplejidad entre $k = 2, 3$ y 4 (Parte 2) quedó incompleta: la subtask falló tras 3 intentos y solo se reporta la perplejidad de $k = 3$ (137.7877). Toda cifra de este reporte proviene de la ejecución medida; no se estimó ninguna.