

Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

Objetivo

Ajustar modelos de Latent Dirichlet Allocation (LDA) al corpus de doce oraciones del curso (cuatro de deporte, cuatro de cocina y cuatro de astronomía, cuyas etiquetas reales LDA no ve) para: (1) con tres temas, reportar el tamaño del vocabulario, las cinco palabras más probables de cada tema y la perplejidad sobre el corpus; (2) comparar la perplejidad de modelos con 2, 3 y 4 temas; (3) evaluar si LDA recupera los tres temas reales asignando a cada documento su tema dominante y calculando la pureza; y (4) discutir qué añade LDA frente a pLSI y por qué este corpus es un mal escenario para el modelo.

Método

El flujo se implementó en Python con scikit-learn; todas las cifras de este reporte provienen de la ejecución.

- **Vectorización.** `CountVectorizer` con la lista de palabras vacías del enunciado y el resto de parámetros por defecto. El corpus queda en 12 documentos, vocabulario de 71 palabras y 91 tokens tras quitar las palabras vacías.
- **Modelo.** `LatentDirichletAllocation(n_components=k, learning_method="batch", max_iter=50, random_state=0)`, con el mismo vectorizador y los mismos hiperparámetros en todas las partes.
- **Parte 1.** Ajuste con $k=3$: palabras top por tema con sus probabilidades y perplejidad sobre el corpus.
- **Parte 2.** Ajustes con $k=2, 3$ y 4 : tabla comparativa de perplejidad sobre el corpus completo.
- **Parte 3.** Con el modelo $k=3$ de la Parte 1: tema dominante de cada documento (componente mayor de su mezcla), etiqueta real mayoritaria de cada tema LDA y pureza = suma de los conteos de la etiqueta mayoritaria por tema dividida por 12.
- **Parte 4.** Pregunta conceptual sobre LDA vs. pLSI, respondida en la Discusión con base en Blei et al. (2003).

Resultados

Parte 1 — LDA con tres temas

Vocabulario de 71 palabras. Cinco palabras más probables por tema (probabilidad entre paréntesis):

Tema	Palabras top (p)
1	órbita (0.0351), planetas (0.0351), partido (0.0345), minutos (0.0200), huevos (0.0200)
2	equipo (0.0600), partido (0.0596), liga (0.0341), ganó (0.0339), dos (0.0335)
3	sal (0.0419), nebulosa (0.0419), galaxia (0.0419), estrellas (0.0419), ajo (0.0240)

Perplejidad del modelo ($k=3$) sobre el corpus: **137.7877**.

Parte 2 — Número de temas

k	Perplejidad (corpus)
2	107.8909
3	137.7877
4	156.4198

El menor valor se obtiene con $k=2$ (temas: «lleva, sal, masa, hornea, harina» y «partido, equipo, liga, ganó, galaxia»); con $k=4$ la cocina se divide en dos temas («telescopio, masa, hornea, harina, estrellas» y «cebolla, ajo, lleva, sopa, cocina»). La perplejidad crece con k en el rango probado, y el control de reproducibilidad confirma que el valor con $k=3$ coincide exactamente con el de la Parte 1 (137.7877).

Parte 3 — ¿Recupera LDA los temas reales?

Asignación por documento (numeración de temas de la Parte 1; tema 1 = índice 0 del modelo):

id	Etiqueta real	Tema dominante	p(tema)	Etiqueta mayoritaria del tema	¿Bien agrupado?
d01	deporte	2	0.9320	deporte	sí
d02	deporte	1	0.9005	astronomía	no
d03	deporte	1	0.8985	astronomía	no
d04	deporte	2	0.9157	deporte	sí
d05	cocina	1	0.9294	astronomía	no
d06	cocina	1	0.9135	astronomía	no
d07	cocina	3	0.9236	astronomía	no
d08	cocina	3	0.9378	astronomía	no
d09	astronomía	3	0.9155	astronomía	sí
d10	astronomía	1	0.9160	astronomía	sí
d11	astronomía	3	0.9162	astronomía	sí
d12	astronomía	1	0.9149	astronomía	sí

Composición de los temas: el tema 1 agrupa 2 deporte + 2 cocina + 2 astronomía; el tema 2, 2 deporte; el tema 3, 2 cocina + 2 astronomía. **Pureza = $6/12 = 0.5$** . Quedan mal agrupados seis documentos: d02, d03, d05, d06, d07 y d08.

Discusión

Qué añade LDA frente a pLSI. Según Blei et al. (2003), en pLSI el documento es un índice ficticio de los documentos de entrenamiento: las proporciones $p(z|d)$ solo se aprenden para esos documentos, el número de parámetros ($kV + kM$) crece linealmente con el número de documentos M y el modelo sobreajusta; además, pLSI no es un modelo generativo bien definido de documentos, pues no hay forma natural de asignar probabilidad a un documento nuevo (la heurística de «folding-in» de Hofmann reajusta $k-1$ parámetros sobre los datos de prueba). LDA añade un prior de Dirichlet α sobre las proporciones de temas θ de cada documento, dentro del proceso generativo $\theta \sim \text{Dir}(\alpha)$, $z_n \sim \text{Mult}(\theta)$, $w_n \sim p(w|z, \beta)$: las mezclas de un documento nuevo se marginalizan bajo el prior, de modo que LDA asigna probabilidad a documentos no vistos sin heurísticas y no sobreajusta al crecer k .

Por qué doce oraciones son un mal escenario. Primero, el corpus es diminuto (12 documentos, 91 tokens), de modo que las distribuciones palabra–tema se estiman con co-ocurrencias muy escasas y los temas se contaminan: el tema 1 mezcla astronomía (órbita, planetas) con deporte (partido) y cocina (minutos, huevos), y el tema 3 mezcla cocina (sal, ajo) con astronomía (nebulosa, galaxia, estrellas); solo el tema 2 es puro, lo que explica la pureza de 0.5. Segundo, los documentos son oraciones cortas, por lo que la mezcla posterior de cada uno se concentra casi por completo en un tema (entre 0.8985 y 0.9378) sin que ese tema coincida necesariamente con la etiqueta real: d02 y d03, de deporte, caen en el tema 1 ($p = 0.9005$ y 0.8985) porque «partido» también es probable en ese tema mixto, y d07 y d08, de cocina, caen en el tema 3 por «sal» y «ajo», aunque su etiqueta mayoritaria es astronomía. Tercero, no hay conjunto de prueba: la perplejidad se calcula sobre el mismo corpus de entrenamiento, de modo que premia al modelo más simple ($k=2$, 107.8909) en lugar de identificar los tres temas reales, y la ventaja central de LDA —generalizar a documentos nuevos gracias al prior de Dirichlet— no puede observarse con tan pocos datos.