

Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

MMIA 6013 · Taller 03 v2 · reporte.pdf

Objetivo

Ajustar Latent Dirichlet Allocation (LDA) a un corpus de doce oraciones etiquetadas en tres temas reales —deporte, cocina y astronomía— que el modelo no ve. Se persigue: (1) ajustar LDA con 3 temas y reportar el tamaño del vocabulario, las cinco palabras más probables por tema y la perplejidad; (2) comparar la perplejidad con 2, 3 y 4 temas; (3) evaluar si los temas latentes recuperan las etiquetas reales mediante la pureza; y (4) discutir qué añade LDA frente a pLSI y por qué un corpus de doce oraciones es un mal escenario para LDA.

Método

- **Vectorización:** `CountVectorizer` con la lista de palabras vacías del enunciado (el, la, los, las, de, del, en, y, a, un, una, por, para, con, se, su, al, es, después, durante, contra, donde, alrededor) y el resto de parámetros por defecto. Resultado: 12 documentos, 71 palabras de vocabulario y 91 tokens.
- **Modelo:** `LatentDirichletAllocation(n_components=k, learning_method="batch", max_iter=50, random_state=0)`, con $k=3$ (Partes 1 y 3) y $k \in \{2, 3, 4\}$ (Parte 2), siempre con el mismo vectorizador.
- **Perplejidad:** evaluada con `perplexity` sobre el propio corpus.
- **Pureza (Parte 3):** a cada documento se le asigna su tema dominante (mayor componente de su distribución documento-tema); por cada tema de LDA se cuenta la etiqueta real más frecuente entre sus documentos y la pureza es la suma de esas cuentas dividida por 12.
- La semilla fija hace reproducibles los resultados: la perplejidad con 3 temas coincide exactamente entre las Partes 1 y 2 (diferencia 0.0), con vocabulario idéntico.

Resultados

Parte 1 — LDA con 3 temas

Vocabulario de 71 palabras; perplejidad sobre el corpus: 137.7877.

Tema	Cinco palabras más probables (peso)
tema_0	órbita (2.3324), planetas (2.3324), partido (2.2923), minutos (1.3325), huevos (1.3325)
tema_1	equipo (2.3922), partido (2.3738), liga (1.3593), ganó (1.3486), dos (1.3330)
tema_2	sal (2.3328), nebulosa (2.3326), galaxia (2.3326), estrellas (2.3326), ajo (1.3382)

Parte 2 — Perplejidad según el número de temas

n_temas	Perplejidad	n_iter
2	107.8909	50
3	137.7877	50
4	156.4198	50

El modelo con menor perplejidad es el de 2 temas (107.8909); la perplejidad crece con k .

Parte 3 — Asignación por documento y pureza

id	Tema real	Tema dominante	p(tema dominante)	Bien agrupado
d01	deporte	1	0.9320	sí
d02	deporte	0	0.9005	sí
d03	deporte	0	0.8985	sí
d04	deporte	1	0.9157	sí

d05	cocina	0	0.9294	no
d06	cocina	0	0.9135	no
d07	cocina	2	0.9236	sí
d08	cocina	2	0.9378	sí
d09	astronomía	2	0.9155	no
d10	astronomía	0	0.9160	no
d11	astronomía	2	0.9162	no
d12	astronomía	0	0.9149	no

Pureza = $6/12 = 0.5000$. Quedan mal agrupados d05 y d06 (cocina $\rightarrow$ tema 0, de mayoría deporte), d09 y d11 (astronomía $\rightarrow$ tema 2, de mayoría cocina) y d10 y d12 (astronomía $\rightarrow$ tema 0, de mayoría deporte).

Discusión

LDA frente a pLSI (Parte 4). En pLSI el documento d es un índice ficticio de los documentos de entrenamiento: el modelo aprende $p(z|d)$ solo para esos documentos, no es un modelo generativo bien definido y no hay forma natural de asignar probabilidad a un documento nuevo. Además, sus parámetros ($kV + kM$) crecen linealmente con el número de documentos M , lo que lo hace propenso al sobreajuste; la heurística de «folding-in» sugerida por Hofmann lo mitiga, pero reajusta $k-1$ parámetros sobre los datos de prueba. LDA añade un prior de Dirichlet sobre las proporciones de tema ($\theta \sim \text{Dir}(\alpha)$) dentro de un proceso generativo completo: $N \sim \text{Poisson}(\xi)$, $\theta \sim \text{Dir}(\alpha)$, $z_n \sim \text{Multinomial}(\theta)$ y $w_n \sim p(w_n | z_n, \beta)$. Así, un documento nuevo recibe sus propias proporciones de tema sin heurísticas y el número de parámetros no crece con el corpus.

¿Por qué doce oraciones son un mal escenario para LDA? Con 91 tokens, 71 palabras de vocabulario y documentos de una sola oración, hay muy pocos datos para estimar a la vez las distribuciones tema-palabra y las mezclas documento-tema, y las señales de co-ocurrencia son débiles. Los resultados lo confirman: (i) los temas salen mezclados —tema_0 combina astronomía (órbita, planetas) con deporte (partido) y cocina (minutos, huevos), y tema_2 combina cocina (sal, ajo) con astronomía (nebulosa, galaxia, estrellas)— y solo tema_1 (equipo, partido, liga, ganó) es coherente con un tema real; (ii) la pureza es 0.5000: el tema 0 reúne 2 documentos de cada etiqueta real (empate resuelto como deporte) y el tema 2 mezcla cocina y astronomía (2 y 2), de modo que la mitad de los documentos queda mal agrupada; (iii) la perplejidad favorece 2 temas (107.8909) frente a los 3 reales (137.7877) y aumenta con k (156.4198 con 4), en línea con la observación de Blei et al. de que, al crecer k en un corpus pequeño, la perplejidad tiende a crecer porque los temas no cubren bien todas las palabras. En síntesis, con datos tan escasos el prior domina sobre la evidencia: ni la perplejidad ni los temas latentes recuperan la estructura real del corpus.