

Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

Objetivo

Ajustar Latent Dirichlet Allocation (LDA) al corpus mínimo del curso —doce oraciones con etiqueta real de tres temas (deporte, cocina, astronomía), cuatro documentos por tema, etiqueta que LDA no observa— para: (1) aprender tres temas latentes y reportar el tamaño del vocabulario, las cinco palabras más probables de cada tema y la perplejidad del modelo sobre el corpus; (2) comparar la perplejidad con 2, 3 y 4 temas; (3) evaluar si LDA recupera los temas reales mediante la pureza; y (4) discutir qué añade LDA frente a pLSI según Blei, Ng y Jordan (2003).

Método

- **Vectorización.** `CountVectorizer` con la lista de palabras vacías del enunciado (el, la, los, las, de, del, en, y, a, un, una, por, para, con, se, su, al, es, después, durante, contra, donde, alrededor) y el resto de parámetros por defecto; sin descargar corpus externos.
- **Parte 1.** `LatentDirichletAllocation(n_components=3, learning_method="batch", max_iter=50, random_state=0)` sobre la matriz de conteos de los 12 documentos.
- **Parte 2.** Mismo vectorizador y mismos parámetros con 2, 3 y 4 temas; perplejidad de cada modelo en una sola tabla.
- **Parte 3.** Con el modelo de tres temas: tema dominante por documento y pureza = suma, sobre los temas de LDA, del conteo de la etiqueta real más frecuente entre sus documentos asignados, dividida por 12.
- **Parte 4.** Respuesta conceptual apoyada en Blei et al. (2003).

Resultados

Parte 1 — LDA con tres temas

Vocabulario de 71 palabras sobre 12 documentos; el ajuste (batch, random_state=0) terminó en la iteración 50. Perplejidad sobre el corpus: **137.7878**.

Puesto	tema_0	tema_1	tema_2
1	órbita (0.0351)	equipo (0.0600)	sal (0.0419)
2	planetas (0.0351)	partido (0.0596)	nebulosa (0.0419)
3	partido (0.0345)	liga (0.0341)	galaxia (0.0419)
4	minutos (0.0200)	ganó (0.0339)	estrellas (0.0419)
5	huevos (0.0200)	dos (0.0335)	ajo (0.0240)

Parte 2 — Número de temas (2, 3 y 4)

Subtarea fallida tras 3 intentos: no se obtuvo la ejecución con 2 ni con 4 temas, por lo que la tabla exigida queda incompleta y no existen cifras medidas para esos modelos. La única perplejidad medida es la de 3 temas (Parte 1).

Temas (k)	Perplejidad
2	no disponible (subtarea fallida)
3	137.7878
4	no disponible (subtarea fallida)

Parte 3 — ¿Recupera LDA los temas reales?

Subtarea pendiente por presupuesto agotado: no se calculó la asignación del tema dominante por documento ni la pureza; la tabla por documento exigida por el enunciado no puede presentarse y no se reporta ninguna cifra de pureza.

Discusión

Qué añade LDA frente a pLSI. Según Blei et al. (2003), en pLSI las proporciones de tema $p(z|d)$ están atadas a los documentos de entrenamiento: al evaluar un documento nuevo solo contribuyen los documentos de entrenamiento con proporciones similares, una palabra con probabilidad pequeña en todos los temas constituyentes hace explotar la perplejidad, y la heurística de «folding-in» (Hofmann, 1999) reajusta $k-1$ parámetros sobre los datos de prueba. LDA añade un prior de Dirichlet sobre las proporciones de tema de cada documento, lo que lo convierte en un modelo generativo completo: puede asignar probabilidad a un documento nuevo sin heurísticas, dotándolo de su propio conjunto de proporciones de tema, y sufre menos el sobreajuste al crecer k .

Por qué doce oraciones son un mal escenario para LDA. Con solo 12 documentos cortos, LDA debe estimar simultáneamente las distribuciones documento–tema (12×3) y tema–palabra (3×71): las estadísticas de coocurrencia son escasas, el prior domina sobre los datos y ambas familias de parámetros quedan con alta varianza, además de una perplejidad poco fiable. Los resultados de la Parte 1 lo evidencian: solo tema_1 es coherente (equipo, partido, liga, ganó, dos: deporte), mientras que tema_0 mezcla astronomía (órbita, planetas) con deporte (partido) y cocina (minutos, huevos), y tema_2 mezcla cocina (sal, ajo) con astronomía (nebulosa, galaxia, estrellas). En un corpus tan pequeño LDA no separa limpiamente los tres temas reales, que es justamente lo que la Parte 3 (no ejecutada) habría cuantificado con la pureza.

Estado de ejecución. Completa: Parte 1. No completadas: Parte 2 (fallida tras 3 intentos) y Parte 3 (presupuesto agotado); sus tablas no se incluyen. Ninguna cifra de este reporte es estimada: todas provienen de la ejecución de la Parte 1 o del enunciado.
