

Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

MMIA 6013 · Taller 03 v2 · Entregable: `reporte.pdf` (máximo dos páginas)

Objetivo

Modelar un corpus de doce oraciones rotuladas en tres temas (deporte, cocina, astronomía) con Latent Dirichlet Allocation (LDA; Blei, Ng y Jordan, 2003), sin usar las etiquetas reales. Se busca: (1) ajustar LDA con tres temas y reportar el tamaño del vocabulario, las cinco palabras más probables por tema y la perplejidad sobre el corpus; (2) comparar la perplejidad con 2, 3 y 4 temas; (3) comprobar si los temas latentes recuperan las etiquetas reales mediante la asignación dominante y la pureza; y (4) discutir qué añade LDA frente a pLSI y por qué un corpus tan pequeño es un mal escenario para LDA.

Método

Los doce textos se vectorizaron con `CountVectorizer` y la lista de 23 palabras vacías del enunciado (el, la, los, las, de, del, en, y, a, un, una, por, para, con, se, su, al, es, después, durante, contra, donde, alrededor), con el resto de parámetros por defecto. Sobre la matriz de conteos se ajustó `LatentDirichletAllocation(n_components=3, learning_method="batch", max_iter=50, random_state=0)`. En la Parte 2 se reutilizó el mismo vectorizador y los mismos parámetros con $k = 2, 3$ y 4 . En la Parte 3, cada documento se asigna a su tema dominante (argmax de su mezcla θ) y la pureza se define como la suma, por tema de LDA, de los documentos de la etiqueta real más frecuente entre los asignados a él, dividida entre 12.

Estado de ejecución: la Parte 1 se completó; la Parte 2 (perplejidad con 2, 3 y 4 temas) falló tras 3 intentos y la Parte 3 (pureza del agrupamiento y documentos mal agrupados) agotó su presupuesto. Las cifras faltantes se declaran explícitamente en Resultados.

Resultados

Parte 1 — LDA con tres temas

Tras retirar 23 palabras vacías, el vocabulario queda en 71 términos. La perplejidad del modelo con $k = 3$ sobre el corpus es 137.7877.

Tema	Cinco palabras más probables (peso)
Tema 0	órbita (2.3324), planetas (2.3324), partido (2.2923), minutos (1.3325), huevos (1.3325)
Tema 1	equipo (2.3922), partido (2.3738), liga (1.3593), ganó (1.3486), dos (1.3330)
Tema 2	sal (2.3328), nebulosa (2.3326), galaxia (2.3326), estrellas (2.3326), ajo (1.3382)

Parte 2 — Número de temas

Número de temas (k)	Perplejidad
2	No disponible
3	137.7877 (medida en la Parte 1)
4	No disponible

Faltante declarado: la subtarea T2 (Parte 2 — Perplejidad con 2, 3 y 4 temas) falló tras 3 intentos; las perplejidades de $k = 2$ y $k = 4$ no pudieron medirse.

Parte 3 — ¿Recupera LDA los temas reales?

Documento	Etiqueta real	Tema dominante	θ dominante
d01	deporte	Tema 1	0.9320
d02	deporte	Tema 0	0.9005
d03	deporte	Tema 0	0.8985

d04	deporte	Tema 1	0.9157
d05	cocina	Tema 0	0.9294
d06	cocina	Tema 0	0.9135
d07	cocina	Tema 2	0.9236
d08	cocina	Tema 2	0.9378
d09	astronomía	Tema 2	0.9155
d10	astronomía	Tema 0	0.9160
d11	astronomía	Tema 2	0.9162
d12	astronomía	Tema 0	0.9149

La asignación se deriva de las mezclas documento–tema medidas en la Parte 1; en los doce documentos el tema dominante concentra un peso ≥ 0.8985 . **Faltante declarado:** la subtask T3 (Parte 3 — Pureza del agrupamiento y documentos mal agrupados) agotó su presupuesto, por lo que la pureza numérica no está disponible.

Discusión

Los temas medidos no reproducen limpiamente las tres etiquetas. Solo el Tema 1 es coherente con una etiqueta real (deporte: equipo, partido, liga, ganó). El Tema 2 mezcla cocina y astronomía (sal y ajo junto a nebulosa, galaxia y estrellas), y el Tema 0 mezcla las tres (órbita y planetas con partido, minutos y huevos). En consecuencia, el Tema 0 agrupa documentos de las tres etiquetas (d02 y d03 de deporte, d05 y d06 de cocina, d10 y d12 de astronomía) y el Tema 2 agrupa cocina (d07, d08) con astronomía (d09, d11); solo el Tema 1 (d01, d04) queda puro en etiqueta. Aunque la pureza no pudo calcularse, la tabla anterior muestra ese solapamiento, atribuible al tamaño del corpus: doce oraciones cortas y un vocabulario de 71 palabras dan estadísticas de co-ocurrencia insuficientes para identificar tres distribuciones palabra–tema bien separadas.

Según Blei et al. (2003), pLSI trata las proporciones de tema de cada documento como parámetros libres, lo que produce sobreajuste cuando crece k : un documento nuevo solo puede usar proporciones vistas en el entrenamiento y su perplejidad puede «explotar» si contiene palabras improbables en todos los temas; la heurística de «folding-in» (Hofmann, 1999) lo compensa refiteando $k - 1$ parámetros sobre los datos de prueba. LDA añade un prior de Dirichlet sobre las proporciones de tema (y sobre las distribuciones palabra–tema), lo que lo convierte en un modelo generativo completo: puede asignar probabilidad a un documento nuevo sin heurísticas, dotándolo de proporciones de tema distintas de las de los documentos de entrenamiento, y el suavizado del prior evita la explosión de la perplejidad.

Un corpus de doce oraciones es un mal escenario para LDA porque el modelo necesita muchas co-ocurrencias palabra–palabra para estimar los temas. Con cuatro documentos por etiqueta, el prior domina la evidencia, los temas resultantes mezclan etiquetas (como se observó) y tanto la perplejidad como la selección de k (Parte 2, incompleta) resultan poco estables e informativas.