

Tarea A — ¿Gana el generativo con pocos datos? Ng y Jordan sobre dígitos

MMIA 6013 · Tarea de práctica para el solver multiagente (Taller 03 v2) Entrega: un reporte en Markdown (`reporte.md`) con el código que lo produce.

Ng y Jordan (2001), *On Discriminative vs. Generative Classifiers* (corpus del curso), sostienen que un clasificador generativo como Naive Bayes se acerca a su error asintótico con menos ejemplos que su par discriminativo, la regresión logística, aunque ese error asintótico sea mayor. Esta tarea pone a prueba esa afirmación sobre un conjunto de datos de imágenes.

Parte 1 — Datos y partición

Carga el conjunto de dígitos manuscritos que trae scikit-learn (`sklearn.datasets.load_digits`). Reporta cuántos ejemplos, cuántos atributos y cuántas clases tiene. Divide los datos en entrenamiento y prueba, 75 % y 25 %, estratificando por la clase, con `random_state=7`. Esa partición es la única de toda la tarea: el conjunto de prueba no se usa para ajustar ni para elegir nada.

Parte 2 — Los dos clasificadores

Entrena un **Naive Bayes gaussiano** (`GaussianNB` con sus valores por defecto) sobre los atributos originales, sin escalar, y una **regresión logística** (`LogisticRegression(max_iter=3000)`) sobre los atributos estandarizados, con un `StandardScaler` que se ajusta solo con el conjunto de entrenamiento. Reporta la exactitud (*accuracy*) y el F1 macro de cada modelo sobre el conjunto de prueba, en una tabla.

Parte 3 — La curva de aprendizaje

Con la partición de la Parte 1, entrena los dos modelos de la Parte 2 con 20, 50, 100, 200 y 400 ejemplos de entrenamiento y con el conjunto de entrenamiento completo. Cada submuestra se obtiene con `train_test_split(X_train, y_train, train_size=m, stratify=y_train, random_state=7)`. Evalúa siempre sobre el mismo conjunto de prueba. Dibuja la exactitud contra el número de ejemplos, con una curva por modelo, y guarda la figura como PNG.

Parte 4 — Discusión

Con tus cifras, di si se observa el cruce que predicen Ng y Jordan y desde qué tamaño conviene cada modelo. Si no se observa, explica qué supuesto del modelo generativo puede fallar en estos datos (piensa en la independencia condicional entre píxeles vecinos).

El reporte

Un `reporte.md` con estas secciones, en este orden: **Introducción**, **Metodología**, **Resultados** (la tabla de la Parte 2 y la figura de la Parte 3), **Discusión** y **Conclusiones**. Máximo **1 000 palabras**. Toda cifra del reporte sale de la ejecución del código entregado.