

Tarea B — Atención escalada y codificación posicional (Vaswani et al., 2017)

MMIA 6013 · Tarea de práctica para el solver multiagente (Taller 03 v2) Entrega: un notebook de Jupyter (.ipynb) **ejecutado**, con las salidas visibles.

El Transformer de *Attention Is All You Need* (corpus del curso) calcula $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$ y suma a cada token una codificación posicional sinusoidal. Usa estas matrices (dos consultas, tres claves de dimensión 4 y sus valores):

Matriz	Fila 1	Fila 2	Fila 3
Q	1.0, 0.0, 1.0, 0.5	0.0, 2.0, 0.0, 1.0	—
K	1.0, 1.0, 0.0, 0.0	0.0, 1.0, 1.0, 0.5	1.0, 0.0, 1.0, 1.0
V	1.0, 0.0	0.0, 1.0	2.0, 2.0

Parte 1 — Atención escalada

Implementa en NumPy la atención escalada con un softmax numéricamente estable (resta el máximo de cada fila). Calcula la matriz de pesos (2×3) y la salida (2×2) para las matrices de arriba, y preséntalas con cuatro decimales.

Parte 2 — Por qué se divide por $\sqrt{d_k}$

Crea **una sola vez** el generador `rng = np.random.default_rng(0)`. Para $d_k = 4, 64$ y 512 , en ese orden, toma `q = rng.standard_normal(d_k)` y después `K = rng.standard_normal((10, d_k))`, y calcula los pesos softmax de los puntajes $K @ q$ **sin escalar y escalados** por $\sqrt{d_k}$. Para cada d_k reporta el peso máximo y la entropía en bits de las dos distribuciones, en una tabla con cuatro decimales.

Parte 3 — Codificación posicional

Calcula la codificación sinusoidal $PE(\text{pos}, 2i) = \sin(\text{pos} / 10000^{(2i/d_{\text{model}})})$ y $PE(\text{pos}, 2i+1) = \cos(\text{pos} / 10000^{(2i/d_{\text{model}})})$ con $d_{\text{model}} = 16$ para las posiciones 0 a 49. Reporta $PE[10, 0]$, $PE[10, 1]$ y $PE[25, 6]$, y dibuja la matriz como un mapa de calor. Después, con la función de atención de la Parte 1, usa $PE[10]$ como consulta y la matriz completa como claves y valores: ¿qué posición recibe el mayor peso y cuánto vale?

Parte 4 — Pregunta conceptual

Explica con las entropías de la Parte 2 qué problema resuelve la división por $\sqrt{d_k}$ y qué le pasaría al gradiente del softmax sin ella. Relaciónalo con lo que dice el paper.

Formato

Un solo notebook, ejecutado de principio a fin sin errores, con una celda de Markdown que encabece cada parte. Las cifras se calculan en el notebook, no se escriben a mano.