

Tarea C — Temas latentes con LDA en un corpus mínimo (Blei, Ng y Jordan, 2003)

MMIA 6013 · Tarea de práctica para el solver multiagente (Taller 03 v2) Entrega: un reporte en PDF (`reporte.pdf`) de dos páginas como máximo, con el código.

Latent Dirichlet Allocation (corpus del curso) modela cada documento como una mezcla de temas y cada tema como una distribución sobre palabras. El corpus son doce oraciones de tres temas; la columna «tema» es la etiqueta real, que LDA **no** ve. Los datos están completos en este enunciado: no descargues ningún otro corpus (por ejemplo 20 Newsgroups).

Corpus

id	texto	tema
d01	El delantero marcó dos goles en el partido de fútbol y el equipo ganó la liga.	deporte
d02	El entrenador del equipo preparó la defensa para el partido final de la liga.	deporte
d03	La tenista ganó el torneo después de un partido largo contra la campeona.	deporte
d04	El equipo de baloncesto perdió el partido por un punto en el último segundo.	deporte
d05	La receta lleva harina, huevos y azúcar; la masa se hornea durante treinta minutos.	cocina
d06	Para la salsa se sofríe cebolla y ajo en aceite y se añade tomate.	cocina
d07	El pan se hornea con harina, agua, sal y levadura después de amasar la masa.	cocina
d08	La sopa de verduras lleva cebolla, zanahoria, ajo y sal, y se cocina a fuego lento.	cocina
d09	El telescopio observó una galaxia lejana y varias estrellas de la nebulosa.	astronomía
d10	Los planetas giran alrededor de la estrella; la órbita de la Tierra dura un año.	astronomía
d11	La nebulosa es una nube de gas donde nacen estrellas nuevas en la galaxia.	astronomía
d12	El telescopio espacial fotografió planetas y la órbita de una luna de Júpiter.	astronomía

Palabras vacías (pásalas a `CountVectorizer(stop_words=...)` tal cual): el, la, los, las, de, del, en, y, a, un, una, por, para, con, se, su, al, es, después, durante, contra, donde, alrededor.

Parte 1 — LDA con tres temas

Vectoriza los doce textos con `CountVectorizer` y la lista de palabras vacías de arriba (el resto de parámetros por defecto). Ajusta `LatentDirichletAllocation(n_components=3, learning_method="batch", max_iter=50, random_state=0)`. Reporta el tamaño del vocabulario, las cinco palabras más probables de cada tema y la perplejidad del modelo sobre el corpus.

Parte 2 — Número de temas

Con el mismo vectorizador de la Parte 1 y los mismos parámetros, ajusta LDA con 2, 3 y 4 temas y reporta la perplejidad de cada uno en una sola tabla.

Parte 3 — ¿Recupera LDA los temas reales?

Con el modelo de tres temas de la Parte 1, asigna a cada documento su tema dominante y calcula la **pureza**: para cada tema de LDA, cuenta los documentos de la etiqueta real más frecuente entre los asignados a él; suma esas cuentas y divide por 12. Presenta la asignación por documento en una tabla y explica qué documentos quedan mal agrupados y por qué.

Parte 4 — Pregunta conceptual

¿Qué añade LDA frente a pLSI según Blei et al. (el prior de Dirichlet y el modelo generativo para documentos nuevos)? ¿Por qué un corpus de doce oraciones es un mal escenario para LDA?

El reporte

En PDF, dos páginas como máximo, con las secciones **Objetivo**, **Método**, **Resultados** (las tablas de las Partes 2 y 3) y **Discusión**. Toda cifra sale de la ejecución.